PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
NÚCLEO DE EDUCAÇÃO A DISTÂNCIA
Pós-graduação *Lato Sensu* em Ciência de Dados e Big Data

Lucas Severiano Vieira

PREDIÇÃO DE APROVAÇÃO FIES COM NOTAS DO ENEM E IDHM

Belo Horizonte
2022

Lucas Severiano Vieira

PREDIÇÃO DE APROVAÇÃO FIES COM NOTAS DO ENEM E IDHM

Trabalho de Conclusão de Curso apresentado ao Curso de Especialização em Ciência de Dados e Big Data como requisito parcial à obtenção do título de especialista.

Belo Horizonte
2022

SUMÁRIO

1. Introdução

1.1. Contextualização

A cada ano se busca mais profissionais qualificados no mercado de trabalho. Com isso cresce a necessidade de uma formação superior. Porém a demanda nas universidades públicas é muito maior que a quantidade de vagas disponíveis. Pensando em tentar minimizar este problema o Governo Federal por meio do Ministério da Educação (MEC) criou o Fundo de Financiamento Estudantil (FIES), programa destinado a concessão de financiamento para os estudantes do ensino superior privado. O Governo Federal paga as mensalidades durante o curso para a faculdade e o estudante paga ao Governo Federal em vários anos, em pequenas parcelas.

Todos os cursos superiores permitem utilização do FIES, porém o Governo avalia se o curso/faculdade possui uma boa qualidade de ensino por meio de indicadores do MEC.

Para poder utilizar o financiamento, o estudante formado a partir de 2010 deve ter feito o Exame Nacional do Ensino Médio (ENEM), obtendo nota média igual ou maior que 450 pontos e nota da redação igual ou maior que 400 pontos. Além disso a renda familiar do estudante, deve ser de até 3 salários mínimos. (GOV.BR)

1.2. O problema proposto

Nesta etapa foi utilizada a técnica dos 5-Ws, visando dar uma visão correta do problema e solução.

(Why?) Por que esse problema é importante?

Devido ao baixo valor das parcelas, no decorrer dos anos muitos alunos que tiveram aprovação no FIES, deixaram de pagar o financiamento ao Governo Federal. Com isso as regras foram aumentando, junto com a taxa de juros. Outro ponto que não existia vagas limitadas ao uso do FIES, hoje elas são, com isso a necessidade de se adequar a renda

familiar bem como as notas do ENEM se tornaram muito importantes para ter ou não aprovação no financiamento.

(Who?) De quem são os dados analisados? De um governo? Um ministério ou secretaria? Dados de clientes?

Os dados do FIES são do portal de dados abertos do Ministério da Educação (MEC) e os dados do IBGE foram obtidos por meio do Kaggle.

(What?): Quais os objetivos com essa análise? O que iremos analisar?

Analisar a importância das notas do ENEM na concessão do financiamento, bem como fatores econômicos do estudante.

(Where?): Trata dos aspectos geográficos e logísticos de sua análise.

O dataset do FIES consta os dados de todos os estudantes inscritos no Brasil e o dataset do IBGE consta os dados de todos os municípios Brasileiros.

(When?): Qual o período está sendo analisado? A última semana? Os últimos 6 meses? O ano passado?

O dataset do FIES são dos estudantes que tentaram o financiamento no ano de 2021 no segundo semestre. E a dataset do IBGE traz os dados dos anos de 2018, 2014 e 2010.

1.3. Objetivos

O objetivo deste trabalho é identificar através de algoritmos de Machine Learning, fatores que possam identificar a obtenção do FIES pelo estudante, dessa forma colaborando para o entendimento dele da importância do ENEM.

Além disso esta análise poderia ser útil na avaliação por meio do MEC, de quais inscrições poderiam ou não ser aceitas, diminuindo o tempo de verificação dos requisitos.

2. Coleta de Dados

Foram utilizadas 2 fontes de dados distintas para o trabalho, com dados do FIES e dados referentes aos municípios Brasileiros.

O primeiro dataset "*relatorio_inscricao_dados_abertos_fies_22021.csv*" foi extraído do Portal de dados abertos do Ministério da Educação (MEC) no dia 05/08/2022 através do link http://dadosabertos.mec.gov.br/images/conteudo/fies/2021/relatorio_inscricao_dados_abertos_fies_22021.csv Os dados estão na seguinte estrutura:

Nome da coluna/campo	Descrição	Tipo
Ano do processo seletivo	Ano do processo FIES	int64
Semestre do processo seletivo	Semestre do processo FIES	int64
ID do estudante	Código do estudante no FIES	int64
Sexo	Sexo	object
Data de Nascimento	Data de Nascimento do estudante	object
UF de residência	Estado do estudante	object
Municipio de residência	Cidade do estudante	object
Etnia/Cor	Cor do estudante	object
Pessoa com deficiência?	Sim/Não	object
Tipo de escola no ensino médio	Sim/Não	object
Ano conclusão ensino médio	Ano que concluiu o ensino médio	int64
Concluiu curso superior?	Sim/Não	object
Professor rede pública ensino?	Sim/Não	object
Nº de membros Grupo Familiar	Quantidade de pessoas na família	int64
Renda familiar mensal bruta	Renda bruta da família	object
Renda mensal bruta per capita	Renda por pessoa da família	object
Região grupo de preferência	Região do Brasil da faculdade	object
UF	Estado da faculdade	object
Cod.Microrregião	Código da Microrregião	int64

Microrregião	Descrição da Microrregião	object
Cod.Mesorregião	Código da Mesorregião	int64
Mesorregião	Descrição da Mesorregião	object
Conceito de curso do GP	Conceito do curso	object
Área do conhecimento	Área do conhecimento do curso	object
Subárea do conhecimento	Subárea do conhecimento do curso	object
Cod. do Grupo de preferência	Código do curso de preferência	int64
Nota Corte Grupo Preferência	Nota de corte do curso de preferência	object
Opções de cursos da inscrição	Quantidade de cursos inscritos	int64
Nome mantenedora	Nome da faculdade	object
Natureza Jurídica Mantenedora	Natureza Jurídica da faculdade	object
CNPJ da mantenedora	CNPJ da faculdade	int64
Código e-MEC da Mantenedora	Código e-MEC da faculdade	int64
Nome da IES	Descrição da IES	object
Código e-MEC da IES	Código da IES	int64
Organização Acadêmica da IES	Organização da IES	object
Município da IES	Cidade da IES	object
UF da IES	Estado da IES	object
Nome do Local de oferta	Nome e campus da faculdade	object
Código do Local de Oferta	Código da faculdade	int64
Munícipio do Local de Oferta	Cidade da faculdade	object
UF do Local de Oferta	Estado da faculdade	object
Código do curso	Código do curso escolhido	int64
Nome do curso	Nome do curso escolhido	object
Turno	Turno do curso escolhido	object
Grau	Semestral ou Anual	object
Conceito	Conceito do curso IES	object
Média nota Enem	Nota média do Enem	object
Ano do Enem	Ano realizado o Enem	int64
Redação	Nota Redação do Enem	int64
Matemática e suas Tecnologias	Nota Matemática do Enem	object

Linguagens, Códigos e suas Tec	Nota Linguagens do Enem	object
Ciências Natureza e suas Tec	Ciências Natureza do Enem	object
Ciências Humanas e suas Tec	Ciências Humanas do Enem	object
Situação Inscrição Fies	Situação da inscrição	object
Percentual de financiamento	Percentual de financiamento FIES	object
Semestre do financiamento	Semestre do financiamento FIES	object
Qtde semestre financiado	Qtde semestre financiado FIES	float64

O segundo dataset "*Cities_Brazil_IBGE.xlsx*" foi extraído do Kaggle dia 06/09/2022 através do link https://www.kaggle.com/datasets/gabrielrs3/economy-and-population-of-cities-in-brazil-ibge/download?datasetVersionNumber=1 Os dados estão na seguinte estrutura:

Nome da coluna/campo	Descrição	Tipo
IBGECode	Código da cidade no IBGE	float64
LocalCidade	Nome da Cidade	object
LocalUF	Sigla do Estado	object
LocalEstado	Nome do Estado	object
RegiaoBrasil	Região que faz parte no país	object
Latitude	Código da Latitude geográfica	object
Longitude	Código da Longitude geográfica	object
Gentilico	Nome dado a quem nasce na cidade	object
PopEstimada_2018	População estimada em 2018	float64
PopCenso 2010	Censo demográfico em 2010	float64
IDHM	Índice de desenvolvimento humano	object
ReceitasRealizadas_2014	Receitas em 2014	float64
DespesasEmpenhadas_2014	Despesas em 2014	float64
Pib_2014	Produto interno bruno de 2014	object

O relacionamento entre os datasets foi feito entre as cidades e estados, sendo estes valores únicos no segundo dataset.

3. Processamento/Tratamento de Dados

O script foi feito em Python 3.0 no Google Colab.

Foi feita a importação das bibliotecas necessárias para o processamento, tratamento dos dados e criação dos modelos de machine learning.

```
# Import

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# ML

from sklearn import metrics
from sklearn.preprocessing import LabelEncoder
from sklearn.utils import resample
from sklearn.metrics import classification_report, confusion_matrix, roc_curve, roc_auc_score
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.tree import DecisionTreeClassifier
```

Foi feita a importação dos 2 datasets, listando logo abaixo o total de dados obtidos de cada um.

```
# Carga dos dados - FIES

df_fies = pd.read_csv('relatorio_inscricao_dados_abertos_fies_22021.csv', encoding="ISO-8859-1", sep = ';')
df_fies.shape
```

```
(237965, 57)
```

```
[5] # Carga dos dados - Cidades

df_cidades = pd.read_excel('Cities_Brazil_IBGE.xlsx')
df_cidades.shape
```

```
(5570, 14)
```

Após a leitura dos dados, se percebeu diferença na grafia e acentuação nos nomes de algumas cidades (campo chave do relacionamento entre os datasets), com isso foi necessário fazer um tratamento nestes valores nos dados do FIES. Foi criada uma função para ajuste da acentuação.

```
# Função para retirar acentos

def corrigir_nomes(nome):
    nome = nome.replace('¿', "").replace('Ç', 'C').replace('Ã', 'A').replace('Õ', 'O').replace('À', 'A').replace('È', 'E').replace('Ò', 'O').replace('Á', 'A').replace('É', 'E').replace('Í', 'I').replace('Ó', 'O').replace('Ú', 'U')
    return nome
```

E foi feito ajustes na grafia de algumas cidades.

```
[ ] # Ajuste cidades da base do FIES

    df_fies['Município de residência'] = df_fies['Município de residência'].apply(corrigir_nomes)

    df_fies.replace(to_replace = "EMBU", value = "EMBU DAS ARTES", inplace=True)
    df_fies.replace(to_replace = "MOJI MIRIM", value = "MOGI MIRIM", inplace=True)
    df_fies.replace(to_replace = "JI-PARANA", value = "JI PARANA", inplace=True)
    df_fies.replace(to_replace = "SANTA BARBARA D'OESTE", value = "SANTA BARBARA D OESTE", inplace=True)
    df_fies.replace(to_replace = "LIVRAMENTO DE NOSSA SENHORA", value = "LIVRAMENTO DO BRUMADO", inplace=True)
    df_fies.replace(to_replace = "GUAJARA-MIRIM", value = "GUAJARA MIRIM", inplace=True)
    df_fies.replace(to_replace = "IGARAPE-MIRI", value = "IGARAPE-MIRIM", inplace=True)
    df_fies.replace(to_replace = "NOVA BRASILANDIA D'OESTE", value = "NOVA BRASILANDIA D OESTE", inplace=True)
    df_fies.replace(to_replace = "ESPIGAO D'OESTE", value = "ESPIGAO D OESTE", inplace=True)
    df_fies.replace(to_replace = "PINGO-D'AGUA", value = "PINGO D'AGUA", inplace=True)
    df_fies.replace(to_replace = "COLORADO DO OESTE", value = "COLORADO D OESTE", inplace=True)
    df_fies.replace(to_replace = "ITABIRINHA", value = "ITABIRINHA DE MANTENA", inplace=True)
    df_fies.replace(to_replace = "PEROLA D'OESTE", value = "PEROLA D OESTE", inplace=True)
    df_fies.replace(to_replace = "SAO MIGUEL DO GOSTOSO", value = "SAO MIGUEL DE TOUROS", inplace=True)
    df_fies.replace(to_replace = "BALNEARIO PICARRAS", value = "PICARRAS", inplace=True)
    df_fies.replace(to_replace = "SAO JORGE D'OESTE", value = "SAO JORGE D OESTE", inplace=True)
    df_fies.replace(to_replace = "PRESIDENTE CASTELLO BRANCO", value = "PRESIDENTE CASTELO BRANCO", inplace=True)
    df_fies.replace(to_replace = "CAMPO DE SANTANA", value = "TACIMA", inplace=True)
```

Com os dados das cidades corrigidos, foi feito o merge entre os datasets.

```
[ ] # Merge dos Datasets

    df_dados = pd.merge(df_fies, df_cidades,  how='left', left_on=['Município de residência','UF de residência'], right_on = ['LocalCidade','LocalUF'])
    df_dados.shape

    (237965, 71)
```

```
[ ] # Leitura dos dados - Dados agrupados

    df_dados.head()
```

	Ano do processo seletivo	Semestre do processo seletivo	ID do estudante	Sexo	Data de Nascimento	UF de residência	Município de residência	Etnia/Cor	Pessoa com deficiência?	Tipo de escola no ensino médio	...	RegiaoBrasil	Latitude	Longitude	Gentílico	PopEstimada_2018	PopCenso 2010	IDHM	ReceitasRealizadas_2014	DespesasEmpenh
0	2021	2	281805657	M	15/05/00	PR	COLOMBO	PARDA	NÃO	SIM	...	SUL	-252925	-492262	colombense	240840.0	212967.0	0,733	318326.0	
1	2021	2	281805657	M	15/05/00	PR	COLOMBO	PARDA	NÃO	SIM	...	SUL	-252925	-492262	colombense	240840.0	212967.0	0,733	318326.0	
2	2021	2	351067941	M	10/07/94	PR	CURITIBA	BRANCA	NÃO	NÃO	...	SUL	-254195	-492646	curitibano	1917185.0	1751907.0	0,823	6962143.0	
3	2021	2	205906170	M	25/09/89	PR	CURITIBA	BRANCA	NÃO	SIM	...	SUL	-254195	-492646	curitibano	1917185.0	1751907.0	0,823	6962143.0	
4	2021	2	351067085	F	20/07/99	PR	PARANAGUA	BRANCA	NÃO	SIM	...	SUL	-255161	-485225	parnanguara	153666.0	140469.0	0,75	355256.0	

5 rows × 71 columns

Foi excluída colunas que não seriam relevantes para o trabalho.

```
# Deleção das colunas não utilizadas

df_dados = df_dados.drop(['Nome mantenedora','Natureza Jurídica Mantenedora','CNPJ da mantenedora','Código e-MEC da Mantenedora','Nome da IES','Código e-MEC da IES','Organização Acadêmica da IES'],axis=1)

df_dados = df_dados.drop(['Município da IES','UF da IES','Nome do Local de oferta','Código do Local de Oferta','Município do Local de Oferta','UF do Local de Oferta','Grau','Conceito'],axis=1)

df_dados = df_dados.drop(['Região grupo de preferência','UF','Cod.Microrregião','Microrregião','Cod.Mesorregião','Mesorregião','Conceito de curso do GP','Subárea do conhecimento','Área do conhecimento'],axis=1)

df_dados = df_dados.drop(['Opções de cursos da inscrição','Código do curso','Percentual de financiamento','Semestre do financiamento','Qtde semestre financiado','IBGECode'],axis=1)

df_dados = df_dados.drop(['RegiaoBrasil','Latitude','Longitude','Gentílico','Ano do processo seletivo','Semestre do processo seletivo','LocalUF','Município de residência','Data de Nascimento'],axis=1)

df_dados = df_dados.drop(['Professor rede pública ensino?','Ano do Enem','ReceitasRealizadas_2014','DespesasEmpenhadas_2014','PopEstimada_2018','PopCenso 2010'],axis=1)

df_dados = df_dados.drop(['Tipo de escola no ensino médio','UF de residência','Cod. do Grupo de preferência','Ano conclusão ensino médio','ID do estudante','P1b_2014'],axis=1)

df_dados = df_dados.drop(['Renda familiar mensal bruta', 'Pessoa com deficiência?', 'Concluiu curso superior?','Nº de membros Grupo Familiar'],axis=1)
```

Observado os campos restantes e seus respectivos tipos. Em seguida renomeada algumas colunas para facilitar na sua manipulação.

```
[ ] # Informações sobre tipo dos dados

    df_dados.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 237965 entries, 0 to 237964
Data columns (total 16 columns):
 #   Column                          Non-Null Count   Dtype
---  ------                          --------------   -----
 0   Sexo                            237965 non-null  object
 1   Etnia/Cor                       237965 non-null  object
 2   Renda mensal bruta per capita   237965 non-null  object
 3   Nota Corte Grupo Preferência    237965 non-null  object
 4   Nome do curso                   237965 non-null  object
 5   Turno                           237965 non-null  object
 6   Média nota Enem                 237965 non-null  object
 7   Redação                         237965 non-null  int64
 8   Matemática e suas Tecnologias   237965 non-null  object
 9   Linguagens, Códigos e suas Tec  237965 non-null  object
 10  Ciências Natureza e suas Tec    237965 non-null  object
 11  Ciências Humanas e suas Tec     237965 non-null  object
 12  Situação Inscrição Fies         237965 non-null  object
 13  LocalCidade                     237960 non-null  object
 14  LocalEstado                     237960 non-null  object
 15  IDHM                            237948 non-null  object
dtypes: int64(1), object(15)
memory usage: 30.9+ MB
```

```
[ ] # Renomeando colunas

    df_dados.rename(columns={'Etnia/Cor': 'Cor',
                             'Renda mensal bruta per capita': 'Renda_per_capita',
                             'Média nota Enem': 'Media_Enem',
                             'Matemática e suas Tecnologias': 'Matematica',
                             'Linguagens, Códigos e suas Tec': 'Linguagens',
                             'Ciências Natureza e suas Tec': 'Ciencias_natureza',
                             'Ciências Humanas e suas Tec': 'Ciencias_humanas',
                             'Nome do curso': 'Curso',
                             'Nota Corte Grupo Preferência': 'Nota_corte',
                             'Situação Inscrição Fies': 'Situacao'}, inplace = True)
```

Verificação da existência de valores nulos.

```
[15] # Análise de dados faltantes

     df_dados.isnull().sum().sort_values(ascending=False)[:10]
```

```
IDHM              17
LocalCidade        5
LocalEstado        5
Sexo               0
Cor                0
Renda_per_capita   0
Nota_corte         0
Curso              0
Turno              0
Media_Enem         0
dtype: int64
```

Como foram identificados poucos registros nulos, foi decidido remover estes.

```
[16] # Limpeza de dados nulos

     df_dados.dropna(subset=["IDHM"], inplace=True)
     df_dados.dropna(subset=["LocalEstado"], inplace=True)
     df_dados.dropna(subset=["LocalCidade"], inplace=True)
```

Em seguida foram feitas as conversões das variáveis para processamento nos modelos.

```
  # Conversão números

    df_dados['Nota_corte'] = df_dados['Nota_corte'].apply(lambda x: x.replace(",",".")).astype(float)
    df_dados['Media_Enem'] = df_dados['Media_Enem'].apply(lambda x: x.replace(",",".")).astype(float)
    df_dados['Matematica'] = df_dados['Matematica'].apply(lambda x: x.replace(",",".")).astype(float)
    df_dados['Linguagens'] = df_dados['Linguagens'].apply(lambda x: x.replace(",",".")).astype(float)
    df_dados['Ciencias_natureza'] = df_dados['Ciencias_natureza'].apply(lambda x: x.replace(",",".")).astype(float)
    df_dados['Ciencias_humanas'] = df_dados['Ciencias_humanas'].apply(lambda x: x.replace(",",".")).astype(float)
    df_dados['IDHM'] = df_dados['IDHM'].apply(lambda x: x.replace(",",".")).astype(float)
    df_dados['Renda_per_capita'] = df_dados['Renda_per_capita'].apply(lambda x: x.replace(",",".")).astype(float)
```

```
[19] # Conversão categóricos

     label_encoder = LabelEncoder()
     df_dados['Curso'] = label_encoder.fit_transform(df_dados['Curso'])
     df_dados['LocalEstado'] = label_encoder.fit_transform(df_dados['LocalEstado'])
     df_dados['LocalCidade'] = label_encoder.fit_transform(df_dados['LocalCidade'])
```

Foi feita a limpeza da coluna alvo, pois existem algumas situações que não são relevantes, sobrando apenas aqueles que contratam ou não não conseguiram acesso ao FIES.

```
# Limpeza da coluna alvo, apenas vai ser verificado dados contratados ou não

df_dados.drop(df_dados.loc[df_dados['Situacao']=='INSCRIÇÃO POSTERGADA'].index, inplace=True)
df_dados.drop(df_dados.loc[df_dados['Situacao']=='LISTA DE ESPERA'].index, inplace=True)
df_dados.drop(df_dados.loc[df_dados['Situacao']=='OPÇÃO NÃO CONTRATADA'].index, inplace=True)
df_dados.drop(df_dados.loc[df_dados['Situacao']=='PARTICIPACAO CANCELADA PELO CANDIDATO'].index, inplace=True)
df_dados.drop(df_dados.loc[df_dados['Situacao']=='PRÉ-SELECIONADO'].index, inplace=True)
df_dados.drop(df_dados.loc[df_dados['Situacao']=='REJEITADA PELA CPSA'].index, inplace=True)

# Conversão para número
df_dados['Situacao'].replace(['NÃO CONTRATADO', 'CONTRATADA'], [0, 1], inplace=True)

print(df_dados.groupby('Situacao').size())
```

```
Situacao
0    115773
1     22442
dtype: int64
```

Após o tratamento o dataset ficou com a seguinte estrutura.

```
[21] # Estrutura dos dados

df_dados.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 138215 entries, 0 to 237961
Data columns (total 13 columns):
 #   Column             Non-Null Count   Dtype
---  ------             --------------   -----
 0   Renda_per_capita   138215 non-null  float64
 1   Nota_corte         138215 non-null  float64
 2   Curso              138215 non-null  int64
 3   Media_Enem         138215 non-null  float64
 4   Redação            138215 non-null  int64
 5   Matematica         138215 non-null  float64
 6   Linguagens         138215 non-null  float64
 7   Ciencias_natureza  138215 non-null  float64
 8   Ciencias_humanas   138215 non-null  float64
 9   Situacao           138215 non-null  int64
 10  LocalCidade        138215 non-null  int64
 11  LocalEstado        138215 non-null  int64
 12  IDHM               138215 non-null  float64
dtypes: float64(8), int64(5)
memory usage: 14.8 MB
```

4. Análise e Exploração dos Dados

Foram plotados gráficos de como estava a distribuição dos dados por Cor, Sexo e Turno dos cursos.

```
plt.figure(figsize=(15, 8))
plot_chart('Cor', df_dados, df_dados['Cor'].value_counts().index, title='Cor',
           ylabel='Race', xlabel='Cases', hue='Cor')
```

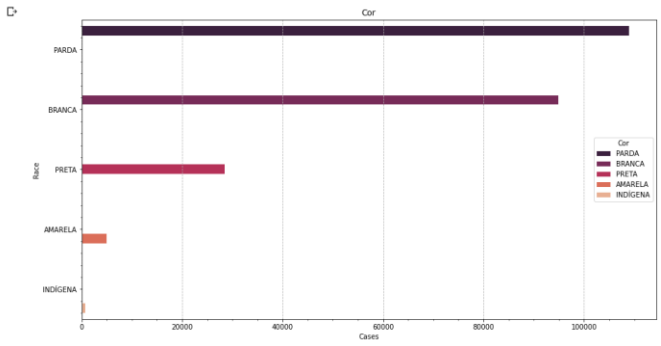

```
plt.figure(figsize=(15, 8))
plot_chart('Sexo', df_dados, df_dados['Sexo'].value_counts().index, title='Sexo',
           ylabel='Race', xlabel='Cases', hue='Sexo')
```

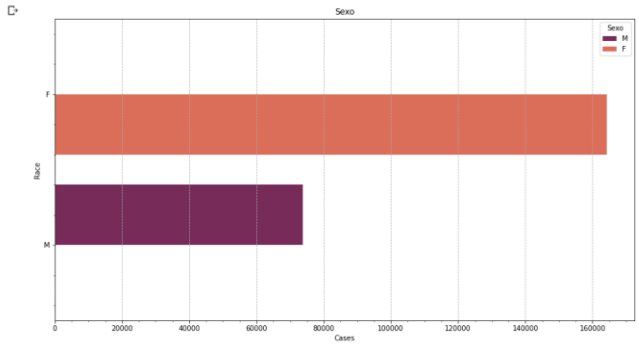


```
[ ] plt.figure(figsize=(15, 8))
    plot_chart('Turno', df_dados, df_dados['Turno'].value_counts().index, title='Turno',
               ylabel='Race', xlabel='Cases', hue='Turno')
```

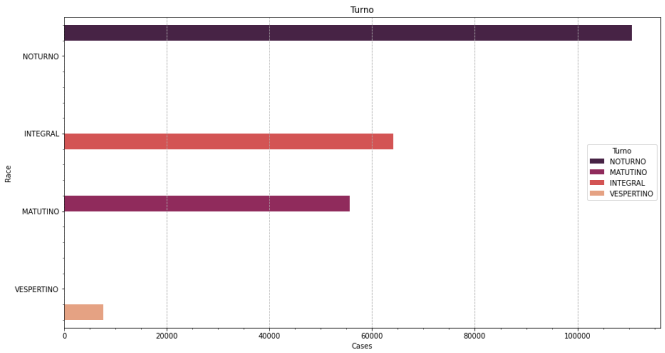

As 3 variáveis (Cor, Sexo, Turno) foram removidas, pois não foram consideradas relevantes para os modelos.

```
[17] #Exclusão de colunas não utilizadas no modelo

     df_dados = df_dados.drop(['Cor', 'Sexo', 'Turno'],axis=1)
```

Feita analise de outliers de todas as variáveis. Observado desvio na variável Renda_per_capita de alguns registros.

```
# Análise de Outliers

numeric_columns = df_dados.select_dtypes(np.number).columns

for col in numeric_columns:
    plt.figure(figsize=(10,5))
    sns.boxplot(y=col, data=df_dados)
    plt.title(col)
    plt.ylabel(None)
    plt.show()
```

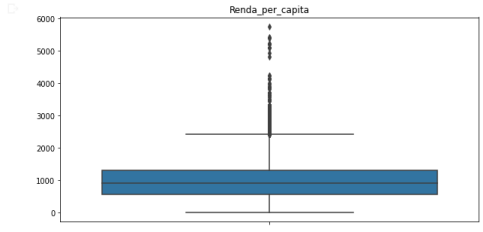

Estes registros da Renda_per_capita foram removidos, bem como foram eliminados os registros que não se adequam as regras do FIES, com relação a Renda, Nota do Enem e Nota da Redação.

```
[27] # Remoção de outliers e cortes da regra do FIES

     df_remove = df_dados.loc[(df_dados['Renda_per_capita'] > 4000) | (df_dados['Media_Enem'] < 450) | (df_dados['Redação'] < 400) ]

     df_dados = df_dados.drop(df_remove.index)
```

Plotado histograma das váriaveis para entendimento das distribuições.

```
print(df_dados.hist(column = ['Renda_per_capita']))
```

```
[[<matplotlib.axes._subplots.AxesSubplot object at 0x7ffb4be7a590>]]
```

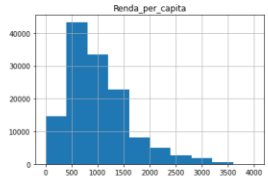


```
[29] print(df_dados.hist(column = ['Nota_corte']))
```

```
[[<matplotlib.axes._subplots.AxesSubplot object at 0x7ffb4bef5e90>]]
```

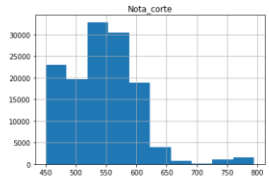


```
[ ] print(df_dados.hist(column = ['Media_Enem']))
```

```
[[<matplotlib.axes._subplots.AxesSubplot object at 0x7f049504ec50>]]
```

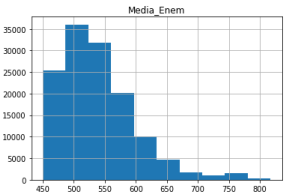


```
[ ] print(df_dados.hist(column = ['Redação']))
```

```
[[<matplotlib.axes._subplots.AxesSubplot object at 0x7f0494fcc310>]]
```

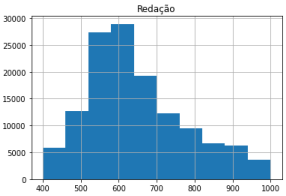

```
[ ] print(df_dados.hist(column = ['Matematica']))
```

```
[[<matplotlib.axes._subplots.AxesSubplot object at 0x7f0494f40dd0>]]
```

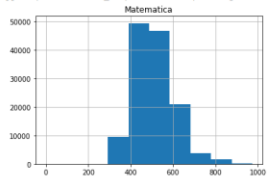


```
[ ] print(df_dados.hist(column = ['Linguagens']))
```

```
[[<matplotlib.axes._subplots.AxesSubplot object at 0x7f0494f62e90>]]
```

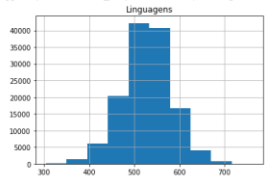


```
[ ] print(df_dados.hist(column = ['Ciencias_natureza']))
```

```
[[<matplotlib.axes._subplots.AxesSubplot object at 0x7f0494eeaf90>]]
```

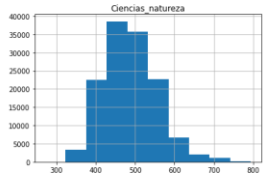


```
[ ] print(df_dados.hist(column = ['Ciencias_humanas']))
```

```
[[<matplotlib.axes._subplots.AxesSubplot object at 0x7f0494e05810>]]
```

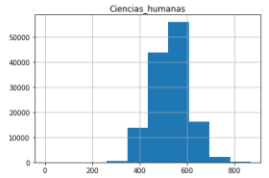


```
[ ] print(df_dados.hist(column = ['IDHM']))
```

```
[[<matplotlib.axes._subplots.AxesSubplot object at 0x7f0494de9ed0>]]
```

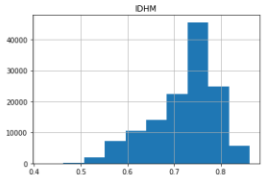

Após foi feita a normalização dos dados.

```
[ ] # Normalização dos dados

    df_max_scaled = df_dados.copy()
    for column in df_max_scaled.columns:
        df_max_scaled[column] = df_max_scaled[column]  / df_max_scaled[column].abs().max()

    display(df_max_scaled)
```

	Renda_per_capita	Nota_corte	Curso	Media_Enem	Redação	Matematica	Linguagens	Ciencias_natureza	Ciencias_humanas	Situacao	LocalCidade	LocalEstado	IDHM
0	0.354420	0.780957	0.277344	0.763668	0.64	0.692718	0.844094	0.679809	0.716325	0.0	0.236602	0.500000	0.850348
1	0.354420	0.780957	0.277344	0.763668	0.64	0.692718	0.844094	0.679809	0.716325	0.0	0.236602	0.500000	0.850348
4	0.208333	0.780957	0.277344	0.626695	0.68	0.419077	0.655906	0.610278	0.561708	0.0	0.649989	0.500000	0.870070
5	0.208333	0.780957	0.277344	0.626695	0.68	0.419077	0.655906	0.610278	0.561708	0.0	0.649989	0.500000	0.870070
7	0.091667	0.780957	0.277344	0.589056	0.60	0.370667	0.729265	0.620733	0.457172	0.0	0.649989	0.500000	0.870070
...	...	...	...	...	...	...	...	...	...	...	...	...	...
237954	0.381250	0.566720	0.093750	0.771695	0.76	0.677231	0.775984	0.682076	0.690997	0.0	0.827218	0.961538	0.933875
237955	0.300000	0.577842	0.347656	0.761906	0.56	0.691795	0.839633	0.732586	0.756850	0.0	0.195686	0.961538	0.868910
237959	0.095833	0.577842	0.347656	0.565856	0.50	0.497333	0.644619	0.494521	0.510592	0.0	0.873916	0.961538	0.933875
237960	0.108332	0.577842	0.347656	0.698204	0.60	0.660000	0.783202	0.630054	0.590030	0.0	0.815877	0.961538	0.945476
237961	0.275000	0.585189	0.398438	0.612917	0.56	0.440821	0.707743	0.645799	0.532696	0.0	0.873916	0.961538	0.933875

132529 rows × 13 columns

Verificado dados estatisticos do dataset.

```
#Estatística dos dados

df_dados.describe()
```

	Renda_per_capita	Nota_corte	Curso	Media_Enem	Redação	Matematica	Linguagens	Ciencias_natureza	Ciencias_humanas	Situacao	LocalCidade	LocalEstado	IDHM
count	132529.000000	132529.000000	132529.000000	132529.000000	132529.000000	132529.000000	132529.000000	132529.000000	132529.000000	132529.000000	132529.000000	132529.000000	132529.000000
mean	1014.299655	544.871342	116.661644	538.934670	636.863720	511.273027	528.092357	487.908448	530.535797	0.163013	2281.116337	13.384920	0.723308
std	590.784878	58.829836	65.521012	60.356753	130.014709	94.252337	54.570407	66.770418	74.086035	0.369379	1335.735446	7.323398	0.070527
min	0.000000	450.020000	0.000000	450.000000	400.000000	0.000000	304.400000	271.000000	0.000000	0.000000	0.000000	0.000000	0.418000
25%	550.000000	503.180000	71.000000	495.340000	540.000000	441.800000	493.900000	438.700000	480.600000	0.000000	1060.000000	6.000000	0.683000
50%	900.000000	545.460000	113.000000	528.660000	600.000000	500.300000	529.300000	482.800000	532.700000	0.000000	2342.000000	13.000000	0.737000
75%	1300.000000	579.980000	192.000000	569.680000	720.000000	568.900000	563.200000	531.200000	579.900000	0.000000	3505.000000	19.000000	0.770000
max	4000.000000	794.820000	256.000000	817.240000	1000.000000	975.000000	762.000000	793.900000	868.600000	1.000000	4497.000000	26.000000	0.862000

Mapa de correlação.

```
# Análise correlação

plt.figure(figsize=(10, 7))
sns.heatmap(df_dados.corr(),
            annot = True,
            fmt = '.2f',
            cmap='Blues')
plt.title('Correlação entre as variáveis')
plt.show()
```

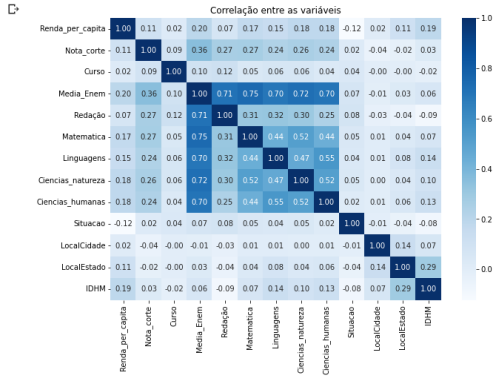

5. Criação de Modelos de Machine Learning

Visando identificar a contratação ou não para o FIES, foram aplicados 3 modelos de Machine Learning. Porém a variável alvo (SITUACAO) se percebeu que estava desbalanceada, assim foi feito o devido tratamento. Foi utilizado o resample para equalizar os valores, assim os algoritmos não serão enviesados devido diferença no tamanho das amostras.

```
# Verificando balanceamento da coluna alvo

balance = df_dados['Situacao'].value_counts(normalize=True).round(2)
balance.index = balance.index.map({0:'NÃO CONTRATADO', 1:'CONTRATADA'})
balance * 100
```

```
NÃO CONTRATADO    84.0
CONTRATADA        16.0
Name: Situacao, dtype: float64
```

```
[71] # Total não efetivados
df_maior = df_dados[df_dados['Situacao'] == 0]
print('linhas:', df_maior.shape[0])
```

```
linhas: 110925
```

```
[72] # Total efetivados
df_menor = df_dados[df_dados['Situacao'] == 1]
print('linhas:', df_menor.shape[0])
```

```
linhas: 21604
```

```
[73] # Igualando quantidade de registros SIM/NÃO
df_unsampled = resample(df_maior, replace = True, n_samples=21603, random_state=123)
```

Após o tratamento, foi avaliado o resultado.

```
# Concatenando registros SIM/NÃO
df_dados = pd.concat([df_unsampled, df_menor])
df_dados.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 43207 entries, 41337 to 237924
Data columns (total 13 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   Renda_per_capita   43207 non-null  float64
 1   Nota_corte         43207 non-null  float64
 2   Curso              43207 non-null  int64
 3   Media_Enem         43207 non-null  float64
 4   Redação            43207 non-null  int64
 5   Matematica         43207 non-null  float64
 6   Linguagens         43207 non-null  float64
 7   Ciencias_natureza  43207 non-null  float64
 8   Ciencias_humanas   43207 non-null  float64
 9   Situacao           43207 non-null  int64
 10  LocalCidade        43207 non-null  int64
 11  LocalEstado        43207 non-null  int64
 12  IDHM               43207 non-null  float64
dtypes: float64(8), int64(5)
memory usage: 4.6 MB
```

```
# Análise balanceamento

import plotly.express as px
plot_ = df_dados['Situacao'].map({1:'CONTRATADA', 0:'NÃO CONTRATADO'}).value_counts().reset_index()
fig = px.bar(plot_,
       x='index',
       y='Situacao',
       labels={'index':'Alvo', 'Situacao':''},
       title='Balanceamente do Alvo',
       width=600)
fig.update_xaxes(type='category')
fig.show()
```

A varável alvo (SITUACAO) foi separada das demais que vão ser utilizadas para predizer o alvo. Em seguida foram separados os dados de treino e teste, sendo 20% teste e 80% treino do algoritmo.

```
# Separação dos Dados - Dataframe
Var_Caracteristicas = df_dados.drop(columns='Situacao')
Var_Previsao = df_dados['Situacao']

# Separação dos Dados - Treino/Teste
x_treino, x_teste, y_treino, y_teste = train_test_split(Var_Caracteristicas, Var_Previsao,test_size=0.20, random_state=10)

print(f'Dados de treino: {len(x_treino)} ')
print(f'Dados de teste: {len(x_teste)} ')
```

```
Dados de treino: 34565
Dados de teste: 8642
```

O primeiro modelo escolhido foi a Regressão Logistica que é algoritmo que tem como objetivo produzir, a partir de um conjunto de observações, um modelo que permita a predição de valores tomados por uma variável. Para sua utilização foi importada a classe *LogisticRegression* do pacote *sklearn.linear_model*.

```
# Criação do modelo

logistic_regression = LogisticRegression(random_state= 42, max_iter=10000)
logistic_regression.fit(x_treino, y_treino)

# Classificação
Train_predict = logistic_regression.predict(x_teste)
print(classification_report(y_teste, Train_predict))

# Acurácia
resultado = logistic_regression.score(x_teste, y_teste)
print('Acurácia:', resultado)
```

```
              precision    recall  f1-score   support

           0       0.60      0.54      0.57      4294
           1       0.59      0.64      0.61      4348

    accuracy                           0.59      8642
   macro avg       0.59      0.59      0.59      8642
weighted avg       0.59      0.59      0.59      8642

Acurácia: 0.5930340199028002
```

O segundo modelo escolhido foi a Árvore de Decisão que é um algoritmo utilizado para classificação e para regressão. Assim como um fluxograma, a árvore de decisão estabelece nós que se relacionam entre si por uma hierarquia. Existe o nó-raiz, que é o mais importante, e os nós-folha, que são os resultados. Para sua utilização foi importada a classe *DecisionTreeClassifier* do pacote *sklearn.tree*.

```
# Criação do modelo

tree = DecisionTreeClassifier()
tree.fit(x_treino, y_treino)

# Classificação
Train_predict = tree.predict(x_teste)
print(classification_report(y_teste, Train_predict ))

# Acurácia
resultado = tree.score(x_teste, y_teste)
print('Acurácia:', resultado)
```

```
              precision    recall  f1-score   support

           0       0.62      0.67      0.64      4294
           1       0.65      0.59      0.62      4348

    accuracy                           0.63      8642
   macro avg       0.63      0.63      0.63      8642
weighted avg       0.63      0.63      0.63      8642

Acurácia: 0.6308724832214765
```

O terceiro modelo escolhido foi a Random Forest que é um algoritmo utilizado para problemas que envolvam classificação ou regressão. Ele se baseia em uma coleção de árvores de decisão, combinando os resultados de todos eles para se obter um resultado único e mais eficiente. Para sua utilização foi importada a classe *RandomForestClassifier* do pacote *sklearn.ensemble*.

```
[379] # Criação do modelo

      random_forest = RandomForestClassifier(random_state= 42)
      random_forest.fit(x_treino, y_treino)

      # Classificação
      Train_predict = random_forest.predict(x_teste)
      print(classification_report(y_teste, Train_predict))

      # Acurácia
      resultado = random_forest.score(x_teste, y_teste)
      print('Acurácia:', resultado)
```

```
              precision    recall  f1-score   support

           0       0.68      0.71      0.69      4294
           1       0.70      0.68      0.69      4348

    accuracy                           0.69      8642
   macro avg       0.69      0.69      0.69      8642
weighted avg       0.69      0.69      0.69      8642

Acurácia: 0.6912751677852349
```

6. Interpretação dos Resultados

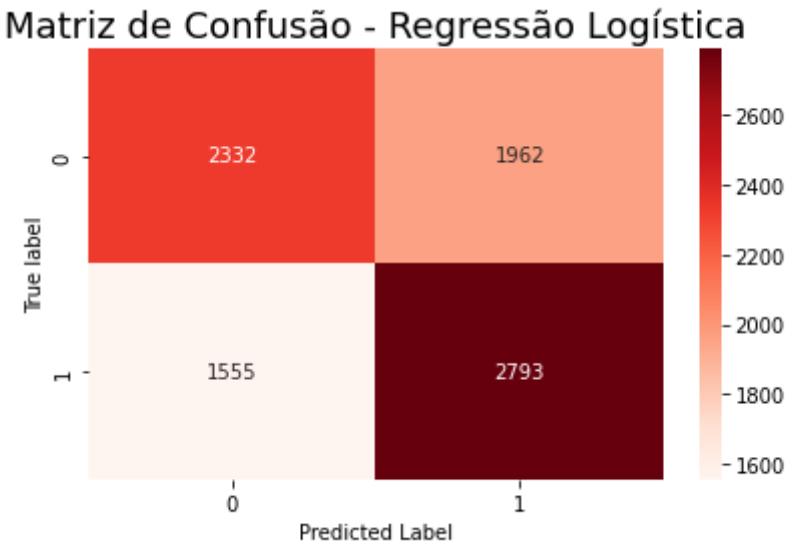

Curva ROC da Regressão Logistica.

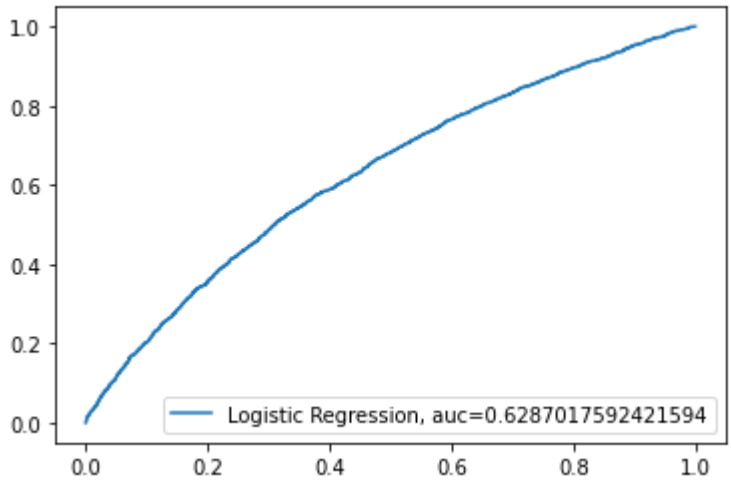

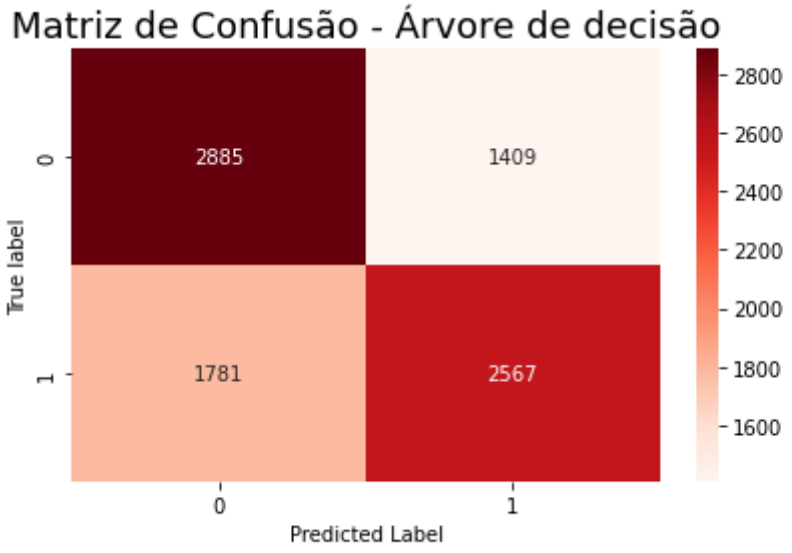

Curva ROC da Árvore de Decisão.

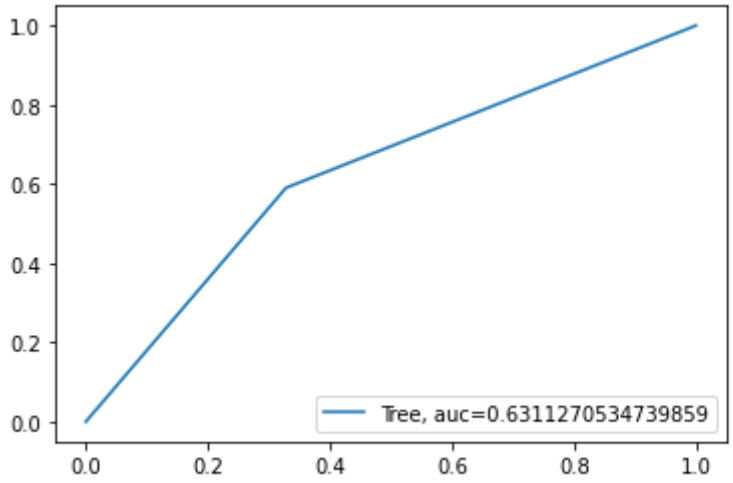

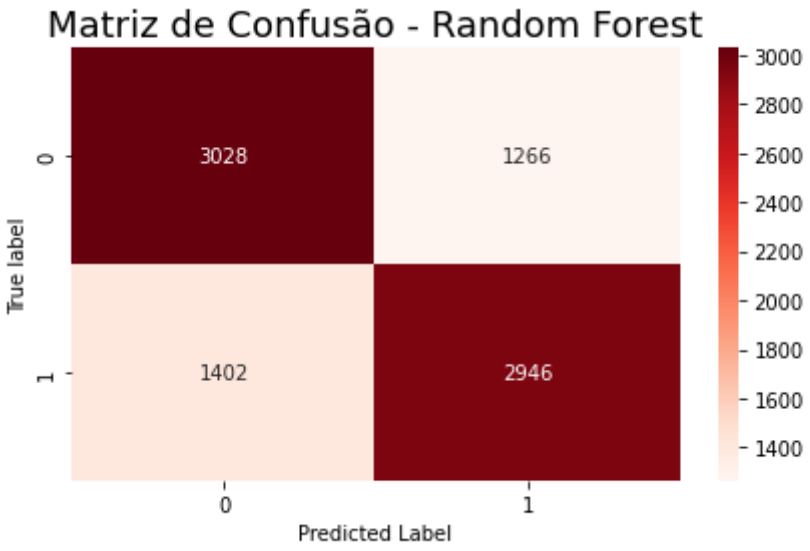

Curva ROC da Random Forest.

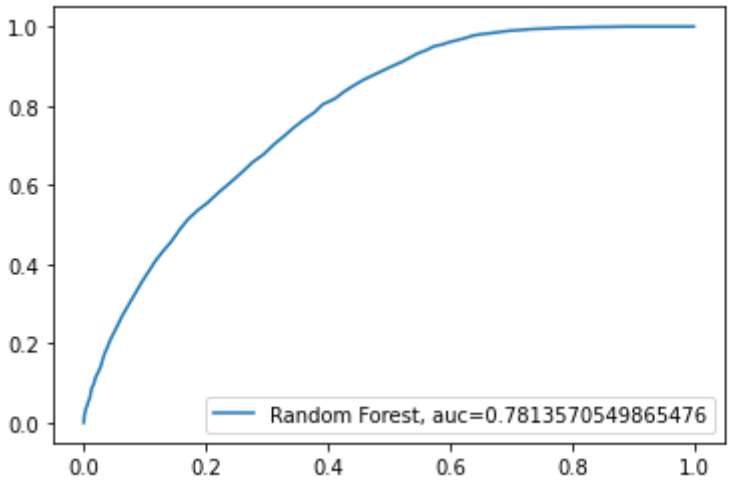

Modelo	Accuracy	Precision	Recall	F1-Score
Regressão logística	59%	59%	54%	57%
Árvore de decisão	63%	65%	67%	64%
Random Forest	69%	70%	71%	69%

7. Apresentação dos Resultados

Data Science Workflow Canvas*

Start here. The sections below are ordered intentionally to make you state your goals first, followed by steps to achieve those goals. You're allowed to switch orders of these steps!

Title: **PREDIÇÃO DE APROVAÇÃO FIES COM NOTAS DO ENEM E IDHM**

1 Problem Statement	2 Outcomes/Predictions	3 Data Acquisition
What problem are you trying to solve? What larger issues do the problem address? Quantidade limitada de vagas no FIES x alto número de estudantes buscando uma vaga no ensino superior.	What prediction(s) are you trying to make? Identify applicable predictor (X) and/or target (y) variables. Determinar, a partir de notas do ENEM, de características econômicas do estudante e do local onde mora, a possibilidade de aprovação no FIES. Variável alvo "Situacao" da inscrição e as demais variáveis preditoras.	Where are you sourcing your data from? Is there enough data? Can you work with it? Dados do portal aberto do MEC dos inscritos no FIES no 2 semestre de 2021 e dados do IBGE.
4 Modeling	**5 Model Evaluation**	**6 Data Preparation**
What models are appropriate to use given your outcomes? Foram feitas classificações com Regressão Logística, Árvore de decisão e Random Forest.	How can you evaluate your model's performance? Índice de acuracidade Classification_Report Matriz de confusão Curva ROC	What do you need to do to your data in order to run your model and achieve your outcomes? Feita coleta dos dados, exclusão de colunas, renomeadas algumas colunas, tratamento de nulos, transformação de tipo de dados, correção de grafia e união dos datasets. Para aplicação dos modelos foi feito balanceamento da coluna alvo, visto quantidade de amostras "não" ser minoritária.

Activation

When you finish filling out the canvas above, now you can begin implementing your data science workflow in roughly this order.

1 Problem Statement → 2 Data Acquisition → 3 Data Prep → 4 Modeling → 5 Outcomes/Preds → 6 Model Eval

* **Note:** This canvas is intended to be used as a starting point for your data science projects. Data science workflows are typically nonlinear.

Conceptualized by Jasmine Vasandani using notes from General Assembly's Data Science Immersive. Format inspired by Business Model Canvas.

8. Links

Link para o vídeo: https://www.youtube.com/watch?v=_jtBEps-Oq8

Link para o repositório: https://github.com/l7vieira/TCC_FIES

REFERÊNCIAS

GOV.BR Disponível em < https://www.gov.br/pt-br/servicos/obter-financiamento-do-fies > Acesso em: 30 out. 2022

APÊNDICE

Programação/Scripts

PUC MINAS

TCC - PÓS GRADUAÇÃO EM CIÊNCIA DE DADOS E BIG DATA

PREDIÇÃO DE APROVAÇÃO DO FIES COM NOTAS DO ENEM E IDHM

LUCAS SEVERIANO VIEIRA

▾ Bibliotecas/Constantes

```
[318] # Import

      import pandas as pd
      import numpy as np
      import matplotlib.pyplot as plt
      import seaborn as sns

      # ML

      from sklearn import metrics
      from sklearn.preprocessing import LabelEncoder
      from sklearn.utils import resample
      from sklearn.metrics import classification_report, confusion_matrix, roc_curve, roc_auc_score
      from sklearn.model_selection import train_test_split
      from sklearn.linear_model import LogisticRegression
      from sklearn.ensemble import RandomForestClassifier
      from sklearn.tree import DecisionTreeClassifier
```

```
# Função para montagem gráficos

def plot_chart(desired_variable, df, order, title=None, xlabel=None, ylabel=None,
               hue=None, ax=None):
    sns.countplot(y=desired_variable,
                  hue=hue,
                  data=df,
                  palette='rocket',
                  order=order,
                  ax=ax).set_title(title)
    plt.xlabel(xlabel=xlabel)
    plt.ylabel(ylabel=ylabel)
    plt.grid(axis='x', linestyle='--')
    plt.minorticks_on()
```

```
[320] # Função para retirar acentos

      def corrigir_nomes(nome):
          nome = nome.replace('¿', "'").replace('Ç', 'C').replace('Ã', 'A').replace('Õ', 'O').replace('Â', 'A').replace('Ê', 'E').replace('Ô', 'O').replace('Á', 'A').replace('É', 'E').replace('Í', 'I').replace('Ó', 'O').replace('Ú', 'U')
          return nome
```

▾ Carga e tratamento dos dados

```
[321] # Carga dos dados - FIES

      df_fies = pd.read_csv('relatorio_inscricao_dados_abertos_fies_22021.csv', encoding="ISO-8859-1", sep = ';')
      df_fies.shape
```

```
[322] # Carga dos dados - Cidades

      df_cidades = pd.read_excel('Cities_Brazil_IBGE.xlsx')
      df_cidades.shape
```

```
[323] # Leitura dos dados - FIES

      df_fies.head()
```

```
[324] # Leitura dos dados - Cidades

      df_cidades.head()
```

```
[325] # Ajuste cidades da base do FIES

      df_fies['Municipio de residência'] = df_fies['Municipio de residência'].apply(corrigir_nomes)

      df_fies.replace(to_replace = "EMBU", value = "EMBU DAS ARTES", inplace=True)
      df_fies.replace(to_replace = "MOJI MIRIM", value = "MOGI MIRIM", inplace=True)
      df_fies.replace(to_replace = "JI-PARANA", value = "JI PARANA", inplace=True)
      df_fies.replace(to_replace = "SANTA BARBARA D'OESTE", value = "SANTA BARBARA D OESTE", inplace=True)
      df_fies.replace(to_replace = "LIVRAMENTO DE NOSSA SENHORA", value = "LIVRAMENTO DO BRUMADO", inplace=True)
      df_fies.replace(to_replace = "GUAJARA-MIRIM", value = "GUAJARA MIRIM", inplace=True)
      df_fies.replace(to_replace = "IGARAPE-MIRI", value = "IGARAPE-MIRIM", inplace=True)
      df_fies.replace(to_replace = "NOVA BRASILANDIA D'OESTE", value = "NOVA BRASILANDIA D OESTE", inplace=True)
      df_fies.replace(to_replace = "ESPIGAO D'OESTE", value = "ESPIGAO D OESTE", inplace=True)
      df_fies.replace(to_replace = "PINGO-D'AGUA", value = "PINGO D'AGUA", inplace=True)
      df_fies.replace(to_replace = "COLORADO DO OESTE", value = "COLORADO D OESTE", inplace=True)
      df_fies.replace(to_replace = "ITABIRINHA", value = "ITABIRINHA DE MANTENA", inplace=True)
      df_fies.replace(to_replace = "PEROLA D'OESTE", value = "PEROLA D OESTE", inplace=True)
      df_fies.replace(to_replace = "SAO MIGUEL DO GOSTOSO", value = "SAO MIGUEL DE TOUROS", inplace=True)
      df_fies.replace(to_replace = "BALNEARIO PICARRAS", value = "PICARRAS", inplace=True)
      df_fies.replace(to_replace = "SAO JORGE D'OESTE", value = "SAO JORGE D OESTE", inplace=True)
      df_fies.replace(to_replace = "PRESIDENTE CASTELLO BRANCO", value = "PRESIDENTE CASTELO BRANCO", inplace=True)
      df_fies.replace(to_replace = "CAMPO DE SANTANA", value = "TACIMA", inplace=True)
```

```
[326] # Merge dos Datasets

      df_dados = pd.merge(df_fies, df_cidades,  how='left', left_on=['Municipio de residência','UF de residência'], right_on = ['LocalCidade','LocalUF'])
      df_dados.shape
```

```
[327] # Leitura dos dados - Dados agrupados

      df_dados.head()
```

```
[328] # Informações sobre tipo dos dados

      df_dados.info()
```

```
[329] # Deleção das colunas não utilizadas

      df_dados = df_dados.drop(['Nome mantenedora','Natureza Jurídica Mantenedora','CNPJ da mantenedora','Código e-MEC da Mantenedora','Nome da IES','Código e-MEC da IES','Organização Acadêmica da IES'],axis=1)

      df_dados = df_dados.drop(['Município da IES','UF da IES','Nome do Local de oferta','Código do Local de Oferta','Município do Local de Oferta','UF do Local de Oferta','Grau','Conceito'],axis=1)

      df_dados = df_dados.drop(['Região grupo de preferência','UF','Cod.Microrregião','Microrregião','Cod.Mesorregião','Mesorregião','Conceito de curso do GP','Subárea do conhecimento','Área do conhecimento'],axis=1)

      df_dados = df_dados.drop(['Opções de cursos da inscrição','Código do curso','Percentual de financiamento','Semestre do financiamento','Qtde semestre financiado','IBGECode'],axis=1)

      df_dados = df_dados.drop(['RegiaoBrasil','Latitude','Longitude','Gentílico','Ano do processo seletivo','Semestre do processo seletivo','LocalUF','Município de residência','Data de Nascimento'],axis=1)

      df_dados = df_dados.drop(['Professor rede pública ensino?','Ano do Enem','ReceitasRealizadas_2014','DespesasEmpenhadas_2014','PopEstimada_2018','PopCenso 2010'],axis=1)

      df_dados = df_dados.drop(['Tipo de escola no ensino médio','UF de residência','Cod. do Grupo de preferência','Ano conclusão ensino médio','ID do estudante','Pib_2014'],axis=1)

      df_dados = df_dados.drop(['Renda familiar mensal bruta', 'Pessoa com deficiência?', 'Concluiu curso superior?','Nº de membros Grupo Familiar'],axis=1)
```

```
[330] # Informações sobre tipo dos dados

      df_dados.info()
```

```
[331] # Renomeando colunas

      df_dados.rename(columns={'Etnia/Cor': 'Cor',
                               'Renda mensal bruta per capita': 'Renda_per_capita',
                               'Média nota Enem': 'Media_Enem',
                               'Matemática e suas Tecnologias': 'Matematica',
                               'Linguagens, Códigos e suas Tec': 'Linguagens',
                               'Ciências Natureza e suas Tec': 'Ciencias_natureza',
                               'Ciências Humanas e suas Tec': 'Ciencias_humanas',
                               'Nome do curso': 'Curso',
                               'Nota Corte Grupo Preferência': 'Nota_corte',
                               'Situação Inscrição Fies': 'Situacao'}, inplace = True)
```

```
[332] # Análise de dados faltantes

      df_dados.isnull().sum().sort_values(ascending=False)[:10]
```

```
[333] # Limpeza de dados nulos

      df_dados.dropna(subset=["IDHM"], inplace=True)
      df_dados.dropna(subset=["LocalEstado"], inplace=True)
      df_dados.dropna(subset=["LocalCidade"], inplace=True)
```

```
[334] # Conversão números

      df_dados['Nota_corte'] = df_dados['Nota_corte'].apply(lambda x: x.replace(",",".")).astype(float)
      df_dados['Media_Enem'] = df_dados['Media_Enem'].apply(lambda x: x.replace(",",".")).astype(float)
      df_dados['Matematica'] = df_dados['Matematica'].apply(lambda x: x.replace(",",".")).astype(float)
      df_dados['Linguagens'] = df_dados['Linguagens'].apply(lambda x: x.replace(",",".")).astype(float)
      df_dados['Ciencias_natureza'] = df_dados['Ciencias_natureza'].apply(lambda x: x.replace(",",".")).astype(float)
      df_dados['Ciencias_humanas'] = df_dados['Ciencias_humanas'].apply(lambda x: x.replace(",",".")).astype(float)
      df_dados['IDHM'] = df_dados['IDHM'].apply(lambda x: x.replace(",",".")).astype(float)
      df_dados['Renda_per_capita'] = df_dados['Renda_per_capita'].apply(lambda x: x.replace(",",".")).astype(float)
```

```
[335] # Conversão categóricos

      label_encoder = LabelEncoder()
      df_dados['Curso'] = label_encoder.fit_transform(df_dados['Curso'])
      df_dados['LocalEstado'] = label_encoder.fit_transform(df_dados['LocalEstado'])
      df_dados['LocalCidade'] = label_encoder.fit_transform(df_dados['LocalCidade'])
```

```
[336] # Limpeza da coluna alvo, apenas vai ser verificado dados contratados ou não

      df_dados.drop(df_dados.loc[df_dados['Situacao']=='INSCRIÇÃO POSTERGADA'].index, inplace=True)
      df_dados.drop(df_dados.loc[df_dados['Situacao']=='LISTA DE ESPERA'].index, inplace=True)
      df_dados.drop(df_dados.loc[df_dados['Situacao']=='OPÇÃO NÃO CONTRATADA'].index, inplace=True)
      df_dados.drop(df_dados.loc[df_dados['Situacao']=='PARTICIPACAO CANCELADA PELO CANDIDATO'].index, inplace=True)
      df_dados.drop(df_dados.loc[df_dados['Situacao']=='PRÉ-SELECIONADO'].index, inplace=True)
      df_dados.drop(df_dados.loc[df_dados['Situacao']=='REJEITADA PELA CPSA'].index, inplace=True)

      # Conversão para número
      df_dados['Situacao'].replace(['NÃO CONTRATADO', 'CONTRATADA'], [0, 1], inplace=True)

      print(df_dados.groupby('Situacao').size())
```

```
[337] # Estrutura dos dados

      df_dados.info()
```

```
[338] plt.figure(figsize=(15, 8))
      plot_chart('Cor', df_dados, df_dados['Cor'].value_counts().index, title='Cor',
                 ylabel='Race', xlabel='Cases', hue='Cor')
```

```
[339] plt.figure(figsize=(15, 8))
      plot_chart('Sexo', df_dados, df_dados['Sexo'].value_counts().index, title='Sexo',
                 ylabel='Race', xlabel='Cases', hue='Sexo')
```

```
[340] plt.figure(figsize=(15, 8))
      plot_chart('Turno', df_dados, df_dados['Turno'].value_counts().index, title='Turno',
                 ylabel='Race', xlabel='Cases', hue='Turno')
```

```
[341] #Exclusão de colunas não utilizadas no modelo

      df_dados = df_dados.drop(['Cor', 'Sexo', 'Turno'],axis=1)
```

```
[ ] # Análise de Outliers

    numeric_columns = df_dados.select_dtypes(np.number).columns

    for col in numeric_columns:
        plt.figure(figsize=(10,5))
        sns.boxplot(y=col, data=df_dados)
        plt.title(col)
        plt.ylabel(None)
        plt.show()
```

```
[343] # Remoção de outliers e cortes da regra do FIES

      df_remove = df_dados.loc[(df_dados['Renda_per_capita'] > 4000) | (df_dados['Media_Enem'] < 450) | (df_dados['Redação'] < 400) ]

      df_dados = df_dados.drop(df_remove.index)
```

```
[344] print(df_dados.hist(column = ['Renda_per_capita']))
```

```
[345] print(df_dados.hist(column = ['Nota_corte']))
```

```
[346] print(df_dados.hist(column = ['Media_Enem']))
```

```
[347] print(df_dados.hist(column = ['Redação']))
```

```
[348] print(df_dados.hist(column = ['Matematica']))
```

```
[349] print(df_dados.hist(column = ['Linguagens']))
```

```
[350] print(df_dados.hist(column = ['Ciencias_natureza']))
```

```
[351] print(df_dados.hist(column = ['Ciencias_humanas']))
```

```
[352] print(df_dados.hist(column = ['IDHM']))
```

```
[353] # Normalização dos dados

      df_max_scaled = df_dados.copy()
      for column in df_max_scaled.columns:
          df_max_scaled[column] = df_max_scaled[column]  / df_max_scaled[column].abs().max()

      display(df_max_scaled)
```

```
[354] #Estatística dos dados

      df_dados.describe()
```

ML

```
[355] # Análise correlação

      plt.figure(figsize=(10, 7))
      sns.heatmap(df_dados.corr(),
                  annot = True,
                  fmt = '.2f',
                  cmap='Blues')
      plt.title('Correlação entre as variáveis')
      plt.show()
```

```
[356] # Verificando balanceamento da coluna alvo

      balance = df_dados['Situacao'].value_counts(normalize=True).round(2)
      balance.index = balance.index.map({0:'NÃO CONTRATADO', 1:'CONTRATADA'})
      balance * 100
```

```
[357] # Total não efetivados
      df_maior = df_dados[df_dados['Situacao'] == 0]
      print('linhas:', df_maior.shape[0])
```

```
[358] # Total efetivados
      df_menor = df_dados[df_dados['Situacao'] == 1]
      print('linhas:', df_menor.shape[0])
```

```
[359] # Igualando quantidade de registros SIM/NÃO
      df_unsampled = resample(df_maior, replace = True, n_samples=21603, random_state=123)
```

```
[360] # Concatenando registros SIM/NÃO
      df_dados = pd.concat([df_unsampled, df_menor])
      df_dados.info()
```

```
[361] # Análise balanceamento

      import plotly.express as px
      plot_ = df_dados['Situacao'].map({1:'CONTRATADA', 0:'NÃO CONTRATADO'}).value_counts().reset_index()
      fig = px.bar(plot_,
             x='index',
             y='Situacao',
             labels={'index':'Alvo', 'Situacao':''},
             title='Balanceamente do Alvo',
             width=600)
      fig.update_xaxes(type='category')
      fig.show()
```

```
[362] # Separação dos Dados - Dataframe
      Var_Caracteristicas = df_dados.drop(columns='Situacao')
      Var_Previsao = df_dados['Situacao']

      # Separação dos Dados - Treino/Teste
      x_treino, x_teste, y_treino, y_teste = train_test_split(Var_Caracteristicas, Var_Previsao,test_size=0.20, random_state=10)

      print(f'Dados de treino: {len(x_treino)} ')
      print(f'Dados de teste: {len(x_teste)} ')
```

Regressão Logística

```
[372] # Criação do modelo

      logistic_regression = LogisticRegression(random_state= 42, max_iter=10000)
      logistic_regression.fit(x_treino, y_treino)

      # Classificação
      Train_predict = logistic_regression.predict(x_teste)
      print(classification_report(y_teste, Train_predict))

      # Acurácia
      resultado = logistic_regression.score(x_teste, y_teste)
      print('Acurácia:', resultado)
```

```
[373] # Matriz de Confusão - Regressão Logística

      fig, ax = plt.subplots()
      sns.heatmap(confusion_matrix(y_teste, Train_predict), annot=True,
                  ax=ax, fmt='d', cmap='Reds')
      ax.set_title("Matriz de Confusão - Regressão Logística", fontsize=18)
      ax.set_ylabel("True label")
      ax.set_xlabel("Predicted Label")
      plt.tight_layout()
```

```
[374] # Curva ROC - Regressão Logística

      y_pred_probability = logistic_regression.predict_proba(x_teste)[::,1]
      fpr, tpr, _ = metrics.roc_curve(y_teste,  y_pred_probability)
      auc = metrics.roc_auc_score(y_teste, y_pred_probability)
      plt.plot(fpr,tpr,label="Logistic Regression, auc="+str(auc))
      plt.legend(loc=4)
      plt.show()
```

Árvore de decisão

```
[375] # Criação do modelo

      tree = DecisionTreeClassifier()
      tree.fit(x_treino, y_treino)

      # Classificação
      Train_predict = tree.predict(x_teste)
      print(classification_report(y_teste, Train_predict ))

      # Acurácia
      resultado = tree.score(x_teste, y_teste)
      print('Acurácia:', resultado)
```

```
[377] # Matriz de Confusão - Árvore de decisão

      fig, ax = plt.subplots()
      sns.heatmap(confusion_matrix(y_teste, Train_predict), annot=True,
                  ax=ax, fmt='d', cmap='Reds')
      ax.set_title("Matriz de Confusão - Árvore de decisão", fontsize=18)
      ax.set_ylabel("True label")
      ax.set_xlabel("Predicted Label")
      plt.tight_layout()
```

```
[378] # Curva ROC - Árvore de decisão

      y_pred_probability = tree.predict_proba(x_teste)[::,1]
      fpr, tpr, _ = metrics.roc_curve(y_teste,  y_pred_probability)
      auc = metrics.roc_auc_score(y_teste, y_pred_probability)
      plt.plot(fpr,tpr,label="Tree, auc="+str(auc))
      plt.legend(loc=4)
      plt.show()
```

Random Forest

```
[379] # Criação do modelo

      random_forest = RandomForestClassifier(random_state= 42)
      random_forest.fit(x_treino, y_treino)

      # Classificação
      Train_predict = random_forest.predict(x_teste)
      print(classification_report(y_teste, Train_predict))

      # Acurácia
      resultado = random_forest.score(x_teste, y_teste)
      print('Acurácia:', resultado)
```

```
[381] # Matriz de Confusão - Random Forest

      fig, ax = plt.subplots()
      sns.heatmap(confusion_matrix(y_teste, Train_predict), annot=True,
                  ax=ax, fmt='d', cmap='Reds')
      ax.set_title("Matriz de Confusão - Random Forest", fontsize=18)
      ax.set_ylabel("True label")
      ax.set_xlabel("Predicted Label")
      plt.tight_layout()
```

```
# Curva ROC - Random Forest

y_pred_probability = random_forest.predict_proba(x_teste)[::,1]
fpr, tpr, _ = metrics.roc_curve(y_teste,  y_pred_probability)
auc = metrics.roc_auc_score(y_teste, y_pred_probability)
plt.plot(fpr,tpr,label="Random Forest, auc="+str(auc))
plt.legend(loc=4)
plt.show()
```